



Universidad Católica Boliviana “San Pablo”
Sede Santa Cruz de la Sierra

Diplomado en Inteligencia Artificial
Módulo: Procesamiento de Imágenes y Visión Computacional

Sistema de Visión Computacional para la Detección de Comercio Informal en la Vía Pública

Transfer learning secuencial COCO → KITTI → Santa Cruz con YOLO11n

Integrantes

Ana Patricia Aban Monzon
Juan Pablo Meriles

Docente

Erick Antero Maraz Zuñiga

Santa Cruz de la Sierra, Bolivia — agosto de 2026

1 Resumen

Las vías públicas de Santa Cruz de la Sierra concentran una alta densidad de puestos y vendedores en acera y calzada, cuyo registro se realiza hoy mediante inspección manual. Este proyecto entrena un detector de objetos capaz de localizar, sobre fotografías tomadas a nivel de calle, tres elementos del comercio en vía pública puestos o estructuras (**street_stall**), vendedores (**street_vendor**) y personas sentadas (**person_sitting**) junto con seis clases de contexto vial y peatonal. Se construyó un conjunto propio de 220 imágenes anotadas y se comparó, con hiperparámetros idénticos, una arquitectura YOLO11n entrenada desde cero contra la misma arquitectura sometida a *transfer learning* secuencial en dos etapas: una adaptación de dominio vial sobre KITTI a partir de pesos COCO, y luego una especialización sobre el conjunto local con el *backbone* congelado (**freeze=10**). Sobre el conjunto de prueba, la estrategia secuencial alcanzó **mAP@0.5 = 0,4164** frente a **0,1430** del modelo desde cero, con un *recall* de 0,4227 contra 0,1312. Con un conjunto de datos de este tamaño, el resultado depende más de la transferencia de representaciones que de la arquitectura o del número de épocas, y el modelo obtenido es utilizable como asistente de pre-etiquetado, no como sistema de medición autónomo.

2 Introducción y motivación

Problema. Dada una fotografía tomada a la altura de un peatón en una calle de Santa Cruz de la Sierra, localizar con una caja delimitadora cada puesto, toldo, mesa o carretilla instalado en la vía pública, cada persona que atiende esos puestos, y los elementos de tráfico y flujo peatonal que los rodean. La salida es una lista de cajas con clase y confianza, no una etiqueta única por imagen.

Caso real análogo. Es el mismo problema que resuelven los sistemas de *street-level imagery analytics* de empresas como Mapillary o Numina para inventariar mobiliario urbano: un vehículo recorre la vía y un detector convierte el video en un inventario georreferenciado. La diferencia está en el catálogo de clases, que no existe en los *datasets* públicos de conducción autónoma.

Por qué importa. El uso previsto no es el conteo automático definitivo sino el **pre-etiquetado** (*auto-labeling*): una unidad municipal de catastro que deba construir un registro de ocupación de vía pública anota hoy miles de imágenes a mano, y un detector con *recall* razonable convierte esa tarea en una de revisión y corrección de cajas propuestas. La decisión que alimenta es logística qué tramos priorizar en un relevamiento y el sistema se limita a describir la ocupación observable del espacio: no clasifica situaciones como regulares o irregulares.

3 Datos

3.1 Fuentes y esquema de clases

Se emplearon dos conjuntos con roles distintos. **KITTI** [3], en la distribución de Ultralytics [2], aporta la etapa intermedia: 7.481 imágenes de escena vial (≈ 5.985 de entrenamiento y 1.496 de validación) con 8 clases viales, bajo licencia CC BY-NC-SA 3.0 y descarga automática al ejecutar `src/train.py`. El **conjunto propio de Santa Cruz** aporta la etapa final: 220 fotografías capturadas con teléfono móvil en agosto de 2026 en vías con actividad comercial de la ciudad, anotadas manualmente por el equipo con LabelImg [7] y exportadas a formato YOLO (clase `cx cy w h`, normalizado); son de autoría propia, sin licencia de terceros involucrada.

Se definieron 9 clases. Las seis primeras **car** (0), **van** (1), **truck** (2), **pedestrian** (3), **person_sitting** (4) y **cyclist** (5) conservan deliberadamente los índices y la semántica de KITTI, de modo que la etapa intermedia sea informativa para ellas; las tres últimas **street_vendor** (6), **street_stall** (7) y **motorbike** (8) son propias del dominio.

3.2 Partición y balance

La partición es 70/20/10 sobre la lista de pares imagen–anotación, ordenada alfabéticamente y barajada con semilla fija (`random.Random(0)`): 154 imágenes de entrenamiento, 44 de validación y 22 de prueba. Es una partición *aleatoria por imagen*, no estratificada por clase; con 220 imágenes y 9 categorías una estratificación real no es viable, y la consecuencia se observa en la Tabla 1: **cyclist** no aparece en el conjunto de prueba y **van** lo hace con 2 instancias.

Tabla 1: Distribución de cajas delimitadoras por clase y partición.

Partición	car	van	truck	pedest.	p_sitting	cyclist	vendor	stall	moto	Cajas	Imág.
Entrenamiento	96	23	17	422	50	6	124	368	41	1.147	154
Validación	30	3	12	125	27	2	32	106	10	347	44
Prueba	12	2	3	67	6	0	24	53	6	173	22
% del entrenamiento	8,37	2,01	1,48	36,79	4,36	0,52	10,81	32,08	3,57	100,00	

Abreviaturas: `pedest.` = `pedestrian`, `p_sitting` = `person_sitting`, `vendor` = `street_vendor`, `stall` = `street_stall`, `moto` = `motorbike`.

3.3 Limitaciones conocidas del conjunto de datos

1. **Tamaño.** 220 imágenes y 1.667 cajas en total. Con 173 instancias en prueba, cada objeto no detectado mueve el *recall* global en $\approx 0,6$ puntos: las métricas reportadas tienen un intervalo de confianza amplio.
2. **Riesgo de fuga por grupo.** Las fotografías se tomaron el mismo día y en pocos tramos de calle, de modo que varias imágenes comparten el mismo puesto visto desde ángulos distintos. Como la partición es aleatoria por

imagen y no por escena, un mismo puesto físico puede aparecer en entrenamiento y en prueba, lo que infla las métricas respecto de calles no vistas.

3. **Desbalance severo.** `pedestrian` y `street_stall` concentran el 68,9 % de las cajas de entrenamiento, mientras `cyclist` aporta 6 cajas y `truck` 17: las clases minoritarias no tienen soporte estadístico suficiente para una evaluación seria.
4. **Sesgo de captura y ambigüedad de anotación.** Todas las fotos son diurnas, con buena luz y tomadas a la altura del pecho desde la vereda opuesta. Además, la frontera entre `street_vendor` y `pedestrian` quien atiende frente a quien compra es una decisión de criterio que dos anotadores no aplican de forma perfectamente consistente.
5. **Un archivo corrupto.** Una imagen de prueba está truncada y Ultralytics la descarta automáticamente: la evaluación se realiza sobre 21 imágenes.

4 Metodología

4.1 Arquitectura y justificación

Se usó **YOLO11n** [1, 2]: 2.583.907 parámetros y 6,4 GFLOPs. La elección responde a tres razones concretas del proyecto y no a una preferencia general. Primero, con 154 imágenes de entrenamiento un modelo de mayor capacidad memoriza el conjunto en pocas épocas, y la variante *nano* es la que mejor se ajusta a este régimen de datos. Segundo, el uso previsto pre-etiquetado por lotes y, eventualmente, procesamiento de video exige inferencia barata: el modelo ejecuta en 19,2ms por imagen sobre la GPU de entrenamiento y en **313 ms en CPU**, sin dependencia de CUDA, de modo que revisar un lote de imágenes no requiere GPU. Tercero, existe un *checkpoint* COCO [4] oficial de esta misma arquitectura, requisito para la primera etapa de transferencia.

4.2 Estrategia de transferencia secuencial y modelo de control

La hipótesis del experimento es que la distancia entre COCO (objetos genéricos, encuadres variados) y el dominio final (calle de Santa Cruz, perspectiva peatonal, oclusión densa) es demasiado grande para un salto único, y que una etapa intermedia en un dominio vial reduce ese desajuste [5]:



En la Etapa 2 el *head* de detección se reinicializa automáticamente al cambiar el número de clases ($nc: 8 \rightarrow 9$) y se congelan las 10 primeras capas el *backbone* completo hasta el bloque C2PSA, de modo que el entrenamiento sobre las 154 imágenes locales solo ajusta el cuello y la cabeza de detección; esto evita que un conjunto pequeño destruya los extractores de características ya aprendidos. Para que la comparación sea atribuible a la transferencia, el modelo de control parte de `yolo11n.yaml` (pesos aleatorios) con exactamente los mismos datos, épocas, tamaño de imagen, *batch*, optimizador, aumentaciones y semilla: la única diferencia entre ambas ramas es el punto de partida de los pesos y el congelamiento.

4.3 Preprocesamiento y aumentación

Las imágenes se redimensionan a 640×640 con relleno. La conversión de coordenadas de Pascal VOC a YOLO centro y dimensiones normalizados por el ancho y alto de la imagen se implementó explícitamente y se verifica con una aserción en `src/preparar_datos.py`. Se usaron las aumentaciones por defecto de Ultralytics, idénticas en ambas ramas: mosaico ($p = 1,0$, desactivado en las últimas 10 épocas), volteo horizontal ($p = 0,5$), variación HSV ($h = 0,015$; $s = 0,7$; $v = 0,4$), escala $\pm 0,5$, traslación $\pm 0,1$ y borrado aleatorio ($p = 0,4$). No se aplicó volteo vertical ni rotación: la perspectiva de calle tiene una orientación vertical fija.

4.4 Hiperparámetros

Los valores de la Tabla 2 son los *defaults* de `argparse` en `src/train.py`, de modo que ejecutar el script sin argumentos reproduce el resultado reportado. No se realizó barrido de hiperparámetros no había presupuesto de cómputo ni un conjunto de validación lo bastante grande para que resultara significativo: los valores provienen del laboratorio de la Sesión 10 del curso, con dos ajustes deliberados, 80 épocas en lugar de 30 (con 10 iteraciones por época la curva de validación seguía subiendo) y `freeze=10` por el argumento anterior.

Tabla 2: Hiperparámetros. Las dos ramas comparten todo salvo el origen de los pesos.

	Etapa 1 (KITTI)	Etapa 2 (SCZ, <i>transfer</i>)	Control (desde cero)
Pesos iniciales	<code>yolo11n.pt</code> (COCO)	<code>best.pt</code> de Etapa 1	aleatorios
Épocas / <code>freeze</code>	10 / —	80 / 10	80 / —
Tamaño de imagen / <i>batch</i>	640 / 16	640 / 16	640 / 16
Optimizador	SGD	SGD	SGD
LR inicial / final	0,01 / 0,0001	0,01 / 0,0001	0,01 / 0,0001
<i>Momentum</i> / <i>decay</i>	0,937 / 0,0005	0,937 / 0,0005	0,937 / 0,0005
Semilla	0	0	0
Tiempo (Tesla T4)	18,0 min	12,7 min	13,5 min

5 Resultados

5.1 Etapa intermedia y comparación en el conjunto de prueba

Tras 10 épocas sobre KITTI el modelo alcanzó $\text{mAP@0.5} = 0,607$ y $\text{mAP@0.5:0.95} = 0,371$ sobre las 1.496 imágenes de validación, con **car** en 0,888 y **person_sitting** en 0,356 como extremos. El valor absoluto no es el objetivo —10 épocas están lejos de agotar KITTI—: lo relevante es que estos pesos ya codifican la perspectiva y la escala de una escena de calle antes de ver una imagen de Santa Cruz.

Tabla 3: Métricas globales sobre el conjunto de prueba (21 imágenes, 173 instancias).

Métrica	Desde cero	TL sec.	Factor
mAP@0.5	0,1430	0,4164	$\times 2,91$
mAP@0.5:0.95	0,0483	0,2036	$\times 4,22$
Precisión (P)	0,6224	0,4882	$\times 0,78$
Recall (R)	0,1312	0,4227	$\times 3,22$

Tabla 4: Desempeño por clase del modelo secuencial en prueba. La clase **cyclist** no tiene instancias en este conjunto.

Clase	Inst.	P	R	mAP@0.5	mAP@0.5:0.95
truck	3	0,928	0,667	0,717	0,387
car	12	0,519	0,667	0,572	0,345
street_stall	53	0,527	0,604	0,552	0,209
pedestrian	67	0,669	0,403	0,525	0,253
motorbike	6	0,604	0,500	0,479	0,172
street_vendor	24	0,413	0,375	0,394	0,214
person_sitting	6	0,246	0,167	0,093	0,048
van	2	0,000	0,000	0,000	0,000
Global	173	0,488	0,423	0,416	0,204

La precisión más alta del modelo desde cero es un artefacto y no una ventaja: con un *recall* de 0,13 emite muy pocas detecciones y en varias clases (**truck**, **motorbike**, **person_sitting**) registra precisión 1,000 con *recall* 0,000, es decir, un puñado de detecciones aisladas sobre un fondo de omisiones. En una herramienta de pre-etiquetado el *recall* es la métrica que decide la utilidad: corregir una caja sobrante cuesta un clic, encontrar un objeto omitido cuesta releer la imagen completa.

Las dos clases centrales del problema se comportan de forma distinta. **street_stall**, con 53 instancias, es la mejor sostenida: recupera 6 de cada 10 puestos con precisión 0,527, suficiente para usarlo como propuesta de anotación. **street_vendor** se queda en 0,394 por una razón previsible: un vendedor es visualmente un peatón, y lo que lo distingue es su relación espacial con la mercadería, una señal contextual que un detector de una etapa entrenado con 124 ejemplos no llega a modelar. Los valores de **van** (0,000) y **person_sitting** (0,093) no son un fracaso del modelo: con 2 y 6 instancias, una sola omisión colapsa la métrica.

5.2 Curvas de aprendizaje




Figura 1: Izquierda: pérdida (**box_loss** + **cls_loss**) de entrenamiento en trazo grueso y de validación en trazo claro. Derecha: mAP@0.5 sobre el conjunto de validación, por época. Ambas ramas comparten hiperparámetros y semilla.

La Figura 1 contiene los hallazgos más informativos del experimento. La rama transferida arranca en una pérdida de entrenamiento de 6,08 mientras la rama desde cero arranca en 8,74, y esa brecha nunca se cierra: en la época 80 la primera está en 2,57 y la segunda en 4,77, valor que la rama transferida ya había superado en la época 5. En validación, la rama transferida llega a 0,299 de mAP@0.5 en la época 11, mientras que la rama desde cero permanece por debajo de 0,01 durante las primeras 15 épocas y termina en 0,120. Los picos de la pérdida de validación al comienzo corresponden al calentamiento del *learning rate*, no a inestabilidad del modelo.

Las dos ramas están, sin embargo, en regímenes opuestos. En la rama transferida la pérdida de validación toca su mínimo en la **época 43** (3,854) y luego se estanca y remonta levemente hasta 3,926, mientras la de entrenamiento sigue cayendo: la brecha entre ambas pasa de +0,52 en la época 40 a +1,36 en la 80. Eso es sobreajuste incipiente y, con 154 imágenes, era esperable. Lo llamativo es que el mAP@0.5 de validación *sigue subiendo* en ese tramo, hasta 0,500 en la época 79: el modelo empeora la calibración de sus confianzas —que es lo que castiga la pérdida— mientras continúa afinando la localización y el ordenamiento de las detecciones, que es lo que mide el mAP. La rama desde cero no muestra nada de eso: su pérdida de validación todavía caía en la época 80 y la brecha con entrenamiento es de apenas +0,25. Está sencillamente **subentrenada**.

5.3 Análisis cualitativo



Figura 2: Predicciones del modelo secuencial sobre imágenes del conjunto de prueba, con umbral de confianza 0,25.

En la Figura 2(a) el modelo delimita seis estructuras contiguas bajo toldos, con confianzas entre 0,38 y 0,69, y distingue a cuatro vendedores dentro de esa fila; en la Figura 2(b), sobre una escena más ocluida, recupera el peatón en primer plano con confianza 0,75 y cuatro puestos al fondo, pero omite parte de las personas del segundo plano. Para cuantificar los modos de falla se emparejaron predicciones y anotaciones por IoU sobre 16 fotografías, con 186 casos resultantes: 51,1 % de aciertos, 25,8 % de omisiones, 14,0 % de falsos positivos y 7,5 % de confusiones de clase. Tres mecanismos concentran el 60 % de los errores: personas ocluidas en escenas densas, puestos contiguos que el NMS suprime por solapamiento mutuo, y la confusión `pedestrian` / `street_vendor`. El desglose completo está en el Anexo A.

6 Discusión y limitaciones

Lo que funcionó mejor de lo esperado. La magnitud del efecto de la transferencia: con 154 imágenes la expectativa razonable era una mejora de algunos puntos y el resultado fue casi el triple de $mAP@0.5$. También resultó llamativo que `street_stall` clase que no existe en COCO ni en KITTI y de apariencia muy variable quedara entre las mejor detectadas: los filtros heredados responden a la geometría de toldos y estructuras rectangulares aunque nunca hayan visto esa categoría.

Lo que no funcionó. La separación `street_vendor` / `pedestrian` sigue siendo el cuello de botella, y es un problema de formulación además de datos: son la misma clase visual diferenciada por contexto. La etapa intermedia sobre KITTI, además, aporta menos de lo que promete para las clases nuevas, porque al cambiar nc de 8 a 9 el `head` se reinicializa por completo y lo único que se transfiere son `backbone` y cuello. Por último, el umbral de confianza quedó mal elegido: el 0,25 por defecto de Ultralytics genera 26 falsos positivos cada 95 aciertos, y subirlo a 0,40 elimina el 73 % de ellos a cambio del 14 % de los aciertos (Anexo A).

Señales de sobreajuste. Las hay, y solo en la rama transferida (Figura 1): el modelo empieza a memorizar el conjunto de 154 imágenes a partir de la época 43. La lectura práctica es que había margen para detener el entrenamiento antes con `patience` en torno a 15 épocas se habría obtenido un modelo equivalente en la mitad del tiempo, aunque el `checkpoint` final sigue siendo el mejor de la corrida porque el mAP nunca deja de mejorar. La rama desde cero no da ninguna señal de sobreajuste: se detuvo por presupuesto de épocas, no por convergencia.

Fuga de datos y sesgos. El riesgo de fuga por grupo es la limitación metodológica más seria y está presente: la partición es aleatoria por imagen sobre fotografías tomadas el mismo día en pocos tramos de calle, de modo que un mismo puesto puede estar en entrenamiento y en prueba visto desde otro ángulo. La corrección adecuada es una partición por escena o por cuadra, que exige registrar esa metadata al capturar; mientras no se haga, el 0,4164 reportado debe leerse como una cota superior optimista. A ello se suman el sesgo de captura tomas diurnas, con buen clima y desde una distancia y altura similares y un sesgo geográfico: las zonas fotografiadas son las accesibles al equipo, no una muestra representativa de la ciudad.

Uso responsable. El sistema describe la presencia y ubicación de elementos observables en la vía pública. No identifica personas no se aplicó reconocimiento facial ni infiere condición legal alguna de la actividad detectada, y su salida no constituye evidencia suficiente para ninguna acción administrativa individual.

7 Trabajo futuro

1. **Repartición por escena y captura de metadata.** Registrar coordenada GPS y tramo de calle en cada fotografía y rehacer la partición agrupando por cuadra, de modo que ningún puesto físico aparezca en dos particiones. No mejorará la métrica probablemente la reduzca pero es la única forma de conocer el desempeño real.
2. **Incorporar el conjunto *street-level* de vendedores informales** [6] (≈ 1.400 imágenes anotadas, CC BY 4.0) como tercera etapa intermedia entre KITTI y Santa Cruz: aportaría dos órdenes de magnitud más de ejemplos

de `street_vendor`, hoy la clase más débil.

3. **Ampliar la captura a franja vespertina y nocturna.** Las horas de mayor actividad comercial están sub-representadas en el conjunto actual, enteramente diurno; se necesitan al menos 100 imágenes con iluminación artificial y contraluz.
4. **Reformular `street_vendor` como relación y no como clase.** Detectar `pedestrian` y `street_stall` por separado y derivar la condición de vendedor de la proximidad y el solapamiento entre ambas cajas, en lugar de pedirle al detector que distinga dos siluetas humanas idénticas.

8 Conclusiones

Con 220 imágenes propias y una arquitectura de 2,6 millones de parámetros, el *transfer learning* secuencial COCO → KITTI → Santa Cruz con *backbone* congelado alcanzó $mAP@0.5 = 0,4164$ en prueba frente a 0,1430 del mismo modelo entrenado desde cero bajo hiperparámetros idénticos, con un *recall* 3,2 veces mayor: en un régimen de datos escaso, el punto de partida de los pesos pesa más que cualquier otro factor bajo control del equipo. El modelo resultante sirve como asistente de pre-etiquetado detecta seis de cada diez puestos, en 313 ms por imagen y sin GPU pero no como sistema de medición autónomo, y su desempeño es una cota superior optimista mientras la partición no se realice por escena. El código, los pesos y las instrucciones de reproducción están en <https://github.com/patyaban/Deteccion-Comercio-Informal-SCZ>.

Referencias

- [1] R. Khanam y M. Hussain, “YOLOv11: An Overview of the Key Architectural Enhancements,” *arXiv preprint arXiv:2410.17725*, 2024.
- [2] G. Jocher, J. Qiu y A. Chaurasia, “Ultralytics YOLO11,” 2024. <https://github.com/ultralytics/ultralytics>. Licencia AGPL-3.0.
- [3] A. Geiger, P. Lenz y R. Urtasun, “Are we ready for Autonomous Driving? The KITTI Vision Benchmark Suite,” en *IEEE CVPR*, 2012, pp. 3354–3361.
- [4] T.-Y. Lin *et al.*, “Microsoft COCO: Common Objects in Context,” en *ECCV*, 2014, pp. 740–755.
- [5] J. Yosinski, J. Clune, Y. Bengio y H. Lipson, “How transferable are features in deep neural networks?,” en *NeurIPS*, 2014, pp. 3320–3328.
- [6] D. García-Jaimes *et al.*, “Street-level imagery dataset for the detection of informal vendors in urban environments,” *Data in Brief*, 2025. <https://doi.org/10.5281/zenodo.14635548>. Licencia CC BY 4.0.
- [7] Tzutalin, “LabelImg: Graphical image annotation tool,” 2015. <https://github.com/HumanSignal/labelImg>. Licencia MIT.

A Anexo: análisis de errores

Sobre 16 fotografías anotadas del conjunto propio, con umbral de confianza 0,25 e IoU de emparejamiento 0,5, se analizaron 186 casos: 95 aciertos (51,1 %), 48 omisiones (25,8 %), 26 falsos positivos (14,0 %), 14 confusiones de clase (7,5 %) y 3 detecciones duplicadas (1,6 %). La Tabla 5 agrupa por mecanismo los errores con un patrón identificable; el detalle caso por caso está en [resultados/analisis/](#) del repositorio.

Tabla 5: Modos de falla observados, ordenados por frecuencia.

Modo	N	Hipótesis
Omisión en escena densa	25	Personas y puestos ocluidos entre sí o al fondo, con pocos píxeles. <code>pedestrian</code> (15) y <code>street_vendor</code> (10) concentran la falla.
Omisión en fila de puestos	11	Sin frontera visual entre un puesto y el siguiente, el NMS suprime las cajas intermedias por solapamiento con la del vecino.
Caja mal encuadrada	11	Falsos positivos con IoU entre 0,2 y 0,5: el objeto existe, el recuadro no calza; no son invenciones del modelo.
Omisión de clase vial	9	<code>motorbike</code> , <code>car</code> y <code>truck</code> ocluidos tras puestos, con soporte escaso en el conjunto local (3,6 %, 8,4 % y 1,5 %).
Detección espuria o duplicada	11	Activaciones sobre textura de mercadería y toldos, todas por debajo de 0,35 (8 casos); dos cajas sobre el mismo objeto con solapamiento inferior al umbral de NMS de 0,7 (3).
Confusiones de clase	14	<code>pedestrian</code> frente a <code>street_vendor</code> (6 casos): misma silueta humana, y lo que las separa es la relación espacial con la mercadería, contexto que un detector de una etapa no modela. <code>person_sitting</code> y <code>cyclist</code> (4) no tienen soporte para discriminar postura; carretillas y triciclos comparten estructura con <code>motorbike</code> y <code>truck</code> (2); <code>van</code> frente a <code>truck</code> es una frontera ambigua heredada de KITTI (2).

Elección del umbral de confianza. Los falsos positivos tienen confianza media 0,350 frente a 0,646 de los aciertos, y 18 de los 26 caen por debajo de 0,35. Reevaluar los mismos 186 casos variando el umbral (Tabla 6) muestra que el 0,25 por defecto de Ultralytics no es el adecuado para esta tarea: subirlo a 0,40 elimina el 73 % de los falsos positivos y el 59 % de las confusiones y duplicados a cambio del 14 % de los aciertos, y eleva la precisión de 68,8 % a 85,4 %. Para el pre-etiquetado conviene en principio un umbral bajo, pero con 26 falsos positivos cada 95 aciertos revisar deja de ser más rápido que anotar: 0,40 es el compromiso razonable con este modelo.

Tabla 6: Efecto del umbral de confianza sobre los 186 casos analizados.

Umbral	0,25 (usado)	0,30	0,35	0,40	0,50
Aciertos	95	92	84	82	71
Falsos positivos	26	16	8	7	2
Confusiones y duplicados	17	14	12	7	5
Precisión	68,8 %	75,4 %	80,8 %	85,4 %	91,0 %